

تقرير شرح مشروع تحليل بيانات سرطان الثدي

Breast Cancer Data Analysis — Full Pipeline Explained

لتدريب ومقارنة ثلاث موديلات تعلم آلي (KNN, SVM, Logistic Regression) للتنبؤ هل الورم حميد (B) ولا خبيث (M). كل حاجة اتعملت في المشروع: من تنظيف البيانات، مروراً بتحليلها بصريا (EDA)، تقليل عدد الـ features واختيار أهمها، وصولاً للتقرير ده بيشرح خطوة بخطوة

عدد الحالات في البيانات: 569 حالة | عدد الـ features الأصلية: 30

١. عن البيانات (Dataset)

المحيط، المساحة، درجة النعومة، إلخ)، وعمود التشخيص النهائي: B يعني الورم حميد (Benign)، وM يعني خبيث (Malignant). (Wisconsin Breast Cancer)، وفيها 569 حالة، لكل حالة 30 قياس رقمي مأخوذ من صورة خلايا الورم (زي نصف القطر، البيانات المستخدمة هي مجموعة بيانات سرطان الثدي الشهيرة (Dataset) بنوع الورم (B ولا M) بناء على القياسات دي، وناخد بالنّا نعمل كل خطوات التحضير بشكل صحيح عشان النتيجة تبقى موثوقة. الهدف من المشروع: نبني موديل تعلم آلي يقدر يتنبأ

٢. تنظيف البيانات (Data Cleaning)

اتعملت الخطوات دي بالترتيب:

- شيلنا عمود id لأنه مجرد رقم تعريف للحالة ومالوش أي قيمة في التنبؤ.
- اتأكدنا مغيث قيم فاضية (missing values) في أي عمود — والحمد لله البيانات كانت نظيفة من الأساس.
- اتأكدنا مغيث صفوف متكررة (duplicates).
- عمود diagnosis من حروف (B, M) لأرقام (0, 1) عشان الموديلات تقدر تتعامل معاه — العملية دي اسمها Label Encoding.
- حولنا

٣. تحليل البيانات بصريا (EDA — Exploratory Data Analysis)


قبل ما نبدأ أي نمذجة، لازم نفهم شكل البيانات. أول حاجة شغلناها هي توزيع الكلاسين:



شكل ١ — عدد الحالات الحميدة (B) مقابل الخبيثة (M)

مش كبير جدا لدرجة إنه يعتبر مشكلة خطيرة (imbalance) شديد بيكون لما نسبة الكلاسين تبقى زي 95% مقابل 5% مثلا). البيانات مش متوازنة تماما (357 حالة B مقابل 212 حالة M)، بس الفرق

خريطة الارتباط (Correlation Heatmap)



شكل ٢ — العلاقة بين كل زوج features. اللون الأحمر = علاقة موجبة قوية، الأزرق = علاقة سالبة قوية

حجم الورم). ده معناه إن مش كل الـ 30 feature بيضيفوا معلومة جديدة، وده اللي بيخلينا نحتاج خطوة اختيار الـ features. مرتبطين ببعض بشكل قوي جدا (لأنهم أصلاً بيقيسوا حاجات مرتبطة هندسياً — نصف القطر والمحيط والمساحة كلهم بيوصفوا الملاحظة المهمة هنا: كثير من الـ features (radius, perimeter, area زي)

٤. تجهيز البيانات للنمذجة (Preprocessing)

٤.١ فحص القيم الشاذة (Outliers)

حالات حقيقية (ورم كبير جدا أو صغير جدا فعلا) مش أخطاء في القياس، وشيلها ممكن يضيع معلومة مهمة عن الحالات الحرجة. عشان نكتشف القيم الشاذة في كل عمود. بس قررنا ماشيلهاش، لأن في البيانات الطبية القيم الكبيرة أو الصغيرة جدا غالبا بتمثل استخدمنا طريقة IQR (الفرق بين الربع الأول والثالث)

٤.٢ تقسيم البيانات (Train / Test Split)

الموديل على جزء، ونختبره على جزء ثاني ماشافوش أبدا، عشان نتأكد إنه فعلا بيتعلم القاعدة العامة مش بس بيحفظ البيانات. للتدريب (Train) و20% للاختبار (Test)، مع الحفاظ على نفس نسبة B و M في الجزئين (stratified split). الهدف: ندرب قسمنا البيانات لجزئين: 80%

٤.٣ توحيد المقاييس (Scaling)

معياري = 1. ومهم جدا: عملنا fit على الـ train بس، عشان الموديل ميشوفش ولا معلومة من الـ test قبل الاختبار الحقيقي. الكبيرة بس لأنها أكبر رقميا، مش لأنها أهم فعلا. فاستخدمنا StandardScaler عشان نخلي كل feature بمتوسط = 0 وانحراف لآلاف) وبعضها صغير جدا (زي smoothness أقل من 1). لو سبناهم كده، موديلات زي KNN و SVM هتدي وزن أكبر غلط للأرقام بعض الـ features قيمها كبيرة (زي area ممكن توصل

٥. تقليل الأبعاد — Feature Extraction بالـ PCA

"وتحولهم لمجموعة أصغر من" المكونات feature تقنية بتأخذ الـ 30 PCA (Principal Component Analysis) ترتيبهم بحيث أول مكون يلخص أكبر قدر ممكن من التباين features كل مكون بيكون تجميعية خطية من الـ (Components)، في البيانات، وهكذا (variance) الأصلية، وبيتم


نقدر نفسر أي feature أثر في القرار (لو استخدمنا PCA، المكونات الجديدة مبقاش لها معنى طبي واضح زي radius أو area). الموجودة في البيانات. استخدمنا الخطوة دي للاستكشاف بس، وماستخدمناهاش في تدريب الموديلات النهائية، عشان نفضل في مشروعنا، لقينا إن 10 مكونات بس (بدل الـ 30 feature الأصلية) كافيين عشان يغطوا 95% من المعلومات

٦. اختيار أفضل الـ ANOVA F-test Features

إحصائيا بين حالات B وحالات M ولا لأ. كل ما الـ F-score أعلى، كل ما ده معنى إن الـ feature ده بيغرق أكثر بين الكلاسين. SelectKBest مع اختبار إحصائي اسمه ANOVA F-test. الفكرة: لكل feature، بنحسب هل متوسط قيمته مختلف بشكل واضح بدل PCA، استخدمنا طريقة ثانية اسمها

اخترنا أفضل 15 feature من أصل الـ 30، وهما:

radius_mean, perimeter_mean, area_mean, compactness_mean, concavity_mean, concave points_mean,
radius_se, perimeter_se, area_se, radius_worst, perimeter_worst, area_worst, compactness_worst,
concavity_worst, concave points_worst



شكل ٣ — أقوى 15 feature حسب الـ ANOVA F-score

(concave points_worst (733.7), perimeter_worst (717.2), radius_worst (692.9), concave points_mean (684.5), perimeter_mean (548.4 كانت: 5 features أقوى

(PCA)، فاحنا لسه فاهمين معنى كل feature — ده بيغرق كثير في المجال الطبي لأن الطبيب يقدر يفهم ليه الموديل قرر كده. ملحوظة مهمة: الميزة (Advantage) إن الاختيار ده تم على الـ features الأصلية (مش على مكونات

٧. الموديلات — بناء وتدريب ثلاث موديلات مختلفة

بتقسم بيانات التدريب لـ 5 أجزاء، وتدريب على 4 وتختبر على 1، وتكرر العملية 5 مرات، عشان نتأكد إن النتيجة مش صدفة). وهي أداة بتجرب كل التوليفات الممكنة من الإعدادات، وبتقيم كل توليفة بطريقة اسمها 5-fold Cross-Validation (يعني 3 موديلات مختلفة على نفس الـ 15 feature، وضبطنا إعدادات كل موديل (Hyperparameters) باستخدام GridSearchCV. دربنا

٧.١ KNN — K-Nearest Neighbors

بيشوف أقرب K حالة ليها في بيانات التدريب (حسب المسافة بين القياسات)، ولو أغلبهم M مثلاً، بيصنف الحالة الجديدة M. فكرته بسيطة: عشان يصنف حالة جديدة،

(K = 9, طريقة الوزن = uniform → دقة الـ Cross-Validation: 93.6% | دقة الاختبار (AUC: 0.996 | Test): 93.9%) أفضل إعداد: عدد الجيران

٧.٢ SVM — Support Vector Machine


نقاط من كل كلاس. الإعداد gamma بيتحكم في مدى تأثير كل نقطة، والإعداد C بيتحكم في مدى تسامح الموديل مع الأخطاء. بيحاول يرسم "حد فاصل" (خط أو منحنى) بين الكلاسين بأكبر مسافة ممكنة بينهم وبين أقرب

(C = 10, gamma = 0.1, kernel = rbf → دقة الـ Cross-Validation: 95.8% | دقة الاختبار (AUC: 0.999 | Test): 96.5%) أفضل إعداد:

٧.٣ Logistic Regression

خطية للـ 15 feature. الميزة الكبيرة فيه إنه "قابل للتفسير" — تقدر تشوف بالظبط أي feature زود أو قلل احتمال الخباثة. موديل إحصائي بسيط وسريع، بحسب احتمال (بين 0 و 1) إن الحالة خبيثة، بناء على معادلة

(C = 100 → دقة الـ Cross-Validation: 94.5% | دقة الاختبار (AUC: 0.999 | Test): 96.5%) أفضل إعداد:




شكل ٤ — Confusion Matrix لكل موديل: الصف = القيمة الحقيقية، العمود = تنبؤ الموديل


خطير في المجال الطبي (Missed cancer)، فلازم ناخذ بالناس مش بس من الدقة الكلية، لكن كمان من عدد الأخطاء دي بالذات. (من أعلى يسار لأسفل يمين) هي التنبؤات الصح. أي رقم خارج القطر معناه خطأ — مثلاً لو الموديل قال B وهي فعلاً M، ده خطأ إزاي تقرا الـ Confusion Matrix: القيم على القطر

٨. مقارنة الموديلات

النموذج	دقة Cross-Validation	دقة الاختبار (Test)	AUC
KNN	93.6%	93.9%	0.996
SVM	95.8%	96.5%	0.999
الانحدار اللوجستي	94.5%	96.5%	0.999



شكل ٥ — مقارنة دقة الاختبار بين الموديلات الثلاثة



شكل ٦ — منحنى ROC: كل ما الخط قرب من الزاوية العليا الشمال كل ما الموديل أقوى في التفريق بين B و M

AUC، SVM والانحدار اللوجستي متقاربين جدا وأعلى من KNN، يعني قدرتهم على التفريق بين الحالات الحميدة والخبيثة أقوى بشكل عام. الخلاصة: SVM والانحدار اللوجستي حققوا نفس دقة الاختبار تقريبا (96.5%)، وهما أفضل من KNN (93.9%). لو نظرنا للـ

٩. الخلاصة والملفات الناتجة

النهائية: موديل SVM (أو الانحدار اللوجستي) بدقة اختبار حوالي 96.5% على بيانات ماشافهاش الموديل أبدا أثناء التدريب. للاستكشاف) → اختيار أفضل (ANOVA features) → تدريب وضبط 3 موديلات → مقارنة شاملة بالأرقام والرسومات. النتيجة المشروع مر بخطوات علمية سليمة: تنظيف → تحليل استكشافي (EDA) → توحيد مقاييس → تقليل أبعاد (PCA)

الملفات المتاحة للتحميل من المشروع:

- (كامل) الكود + شرح كل خلية بالعربي + كل الرسومات جاهزة Jupyter Notebook
- ملف CSV نهائي فيه الـ 15 feature المختارة + تشخيص كل حالة + تنبؤ الثلاث موديلات.
- ملفات الموديلات المدربة (.pkl) لكل من KNN, SVM, Logistic Regression — جاهزين للاستخدام من غير إعادة تدريب.